Module 01: Descriptive Statistics and Distributions

সম্পূর্ণ নোট — AI/ML Course

Part 1 — Measures of Central Tendency (কেন্দ্রীয় প্রবণতার পরিমাপ)

Data-র "center" কোথায় সেটা বোঝার জন্য তিনটি measure ব্যবহার করা হয়।

---

1. Mean (গড়)

সব মান যোগ করে মোট সংখ্যা দিয়ে ভাগ করলে Mean পাওয়া যায়।

$$\text{Mean} = \frac{\sum x_i}{n}$$

উদাহরণ: `[10, 12, 14, 16, 18, 100]`

$$\text{Mean} = \frac{10 + 12 + 14 + 16 + 18 + 100}{6} = 28.3$$

> ⚠️ **সমস্যা:** Outlier (যেমন `100`) থাকলে Mean অনেকটা বেড়ে যায় — আসল "center" আর represent করে না।

---

2. Median (মধ্যমান)

Data ছোট থেকে বড় সাজিয়ে ঠিক মাঝের মানটিই Median। এটি data-কে দুটি সমান ভাগে ভাগ করে।

- সংখ্যা **বেজোড়** হলে → মাঝের মানটি নাও
- সংখ্যা **জোড়** হলে → মাঝের দুটির গড় নাও

উদাহরণ: Sorted: `[10, 12, 14, 16, 18, 100]`

$$\text{Median} = \frac{14 + 16}{2} = 15$$

> ✅ Outlier থাকলেও Median প্রভাবিত হয় না — তাই এটিকে **robust measure** বলে।

---

3. Mode (সর্বোচ্চ পুনরাবৃত্তি)

Dataset-এ যে মান **সবচেয়ে বেশিবার** আসে সেটাই Mode।

উদাহরণ: `[2, 2, 3, 3, 3, 4, 5]` → Mode = `3` (৩ বার এসেছে)

> 📌 একটি dataset-এ একাধিক Mode-ও থাকতে পারে।

কোন situation-এ কোনটা ব্যবহার করবো?

Situation	Best Measure	কারণ
Symmetric data (height, temperature)	Mean	সব মান সমানভাবে contribute করে
Skewed data / outlier (income, price)	Median	Outlier-এ প্রভাবিত হয় না
Categorical data (color, gender)	Mode	Non-numeric data-তেও কাজ করে

ML-এ গুরুত্ব

```
from sklearn.impute import SimpleImputer
imputer_mean   = SimpleImputer(strategy='mean')
imputer_median = SimpleImputer(strategy='median')
imputer_mode   = SimpleImputer(strategy='most_frequent')
```

Missing values impute করার সময় data-র distribution দেখে সঠিক strategy বেছে নিতে হয়।

Part 2 — Variance ও Standard Deviation (ছড়িয়ে পড়ার পরিমাপ)

Mean কোথায় সেটা জানলাম। এখন জানবো data **কতটা ছড়িয়ে** আছে।

Variance কী?

Data points গুলো mean থেকে গড়ে কতটা দূরে আছে তার **average squared deviation**।

দুই ধরনের Variance:

	Population Variance (σ^2)	Sample Variance (s^2)
কখন	পুরো population জানা থাকলে	Subset থেকে হিসাব করলে
Formula	$\frac{\sum(x_i-\mu)^2}{n}$	$\frac{\sum(x_i-\bar{x})^2}{n-1}$

> **Bessel's Correction:** Sample-এ `n` দিয়ে ভাগ করলে variance একটু underestimate হয়। তাই `n-1` ব্যবহার করা হয় — এটাই Bessel's Correction। এতে result **unbiased** হয়।

উদাহরণ: `[70, 80, 90]`, Mean = 80

Data Point	$(x - \bar{x})^2$
70	100
80	0
90	100

$$\sigma^2 \text{ (Population)} = \frac{200}{3} \approx 66.67 \qquad s^2 \text{ (Sample)} = \frac{200}{2} = 100$$

Standard Deviation (SD) কী?

Variance-এর **square root** — data-র মতোই same unit-এ থাকে, তাই বুঝতে সহজ।

$$\sigma = \sqrt{\sigma^2} \qquad s = \sqrt{s^2}$$

উদাহরণ: `[70, 80, 90]` → σ = √66.67 ≈ **8.16** মানে scores গুলো mean থেকে সাধারণত ±8 points দূরে থাকে।

Visual — SD-এর অর্থ

```
Small SD → curve লম্বা ও সরু (data কাছাকাছি)
Large SD → curve চওড়া ও চ্যাপ্টা (data ছড়িয়ে)

Normal Distribution-এ:
  ±1σ → 68% data
  ±2σ → 95% data
  ±3σ → 99.7% data
```

ML-এ Variance ও SD-এর ব্যবহার

Feature Scaling (Standardization):

$$z_i = \frac{x_i - \mu}{\sigma}$$

এতে Mean = 0, SD = 1 হয়।

Model-এ Variance মানে:

অবস্থা	সমস্যা
High Variance	Model training data মুখস্থ করে → Overfitting
Low Variance + High Bias	Model খুব সরলভাবে শেখে → Underfitting

> 💡 **মূল লক্ষ্য:** Bias ও Variance-এর মধ্যে সঠিক balance খুঁজে বের করাই ভালো ML model তৈরির মূল চ্যালেঞ্জ।

```
np.var(data, ddof=0)  # Population variance
np.var(data, ddof=1)  # Sample variance
np.std(data, ddof=0)  # Population SD
np.std(data, ddof=1)  # Sample SD
```

Part 3 — Percentile, Quartile, IQR ও Z-Score

Percentile কী?

একটি নির্দিষ্ট মানের **নিচে মোট data-র কত শতাংশ** আছে তা বলে।

$$\text{Percentile Rank} = \frac{\text{number of values below } x}{\text{total values}} \times 100$$

> **উদাহরণ:** তোমার score 90th percentile-এ থাকলে মানে তুমি 90% মানুষের চেয়ে ভালো করেছো।

Quartiles কী?

Quartile হলো বিশেষ Percentile — data-কে **চারটি সমান ভাগে** ভাগ করে।

Quartile	Percentile	অর্থ
Q1	25th	Data-র 25% এর নিচে
Q2	50th	Median
Q3	75th	Data-র 75% এর নিচে

IQR (Interquartile Range) কী?

Data-র **মাঝের 50%** কতটা ছড়িয়ে আছে তার পরিমাপ।

$$\text{IQR} = Q3 - Q1$$

Outlier Detection Rule (IQR Fences):

$$\text{Lower Bound} = Q1 - 1.5 \times IQR$$

$$\text{Upper Bound} = Q3 + 1.5 \times IQR$$

এই দুই সীমার বাইরে যেকোনো মান → **Outlier**

> ✅ IQR নিজেই outlier দ্বারা প্রভাবিত হয় না — তাই Mean বা SD-এর চেয়ে বেশি **reliable**।

Boxplot — Visual Representation

```
          Outlier
            •
      ┌─────────────┐
      │  Q1  │  Q3  │    ← Box = IQR
      └─────────────┘
    Whisker         Whisker
  •                         •
  Min                     Max (outlier বাদে)
```

- Box-এর ভেতরের লাইন = **Median (Q2)**
- Whisker-এর বাইরের বিন্দু = **Outliers**

Z-Score কী?

একটি মান, mean থেকে **কতটি standard deviation দূরে** আছে তা বলে।

$$z = \frac{x - \mu}{\sigma}$$

Z-Score	অর্থ
z = 0	মানটি ঠিক mean-এ
z = 1	Mean-এর 1 SD উপরে
z = -2	Mean-এর 2 SD নিচে
|z| > 3	Outlier হিসেবে ধরা হয়

> Z-Score করার পর → Mean = 0, SD = 1

ML-এ জরুরি যেসব model-এ:

- KNN (distance-based)
- SVM (margin-based)
- Gradient Descent-based models

```python
# Outlier detection — তিনটি পদ্ধতি
# ১. IQR method
lower = Q1 - 1.5 * IQR
upper = Q3 + 1.5 * IQR

# ২. Z-score method (|z| > 2.5)
df['z_score'] = (df['col'] - mean) / std

# ৩. Modified Z-score (robust, skewed data-তে ভালো)
mad = np.median(np.abs(df['col'] - median))
```

```
df['mod_z'] = 0.6745 * (df['col'] - median) / mad
# থ্রেশহোল্ড: |mod_z| > 3.5
```

Part 4 — Distribution Shapes (বিতরণের আকৃতি)

Symmetric Distribution

কেন্দ্রের **দুই পাশে একই রকম** — mirror image।

- Mean = Median = Mode (তিনটিই center-এ)
- সবচেয়ে পরিচিত উদাহরণ → **Normal Distribution**

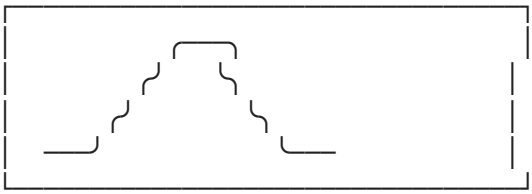

```
Mean=Median=Mode (center)
```

> ✅ Symmetric data-তে Mean ব্যবহার করা সবচেয়ে নির্ভরযোগ্য। Linear Regression, SVM, KNN — এই algorithm গুলো normal distribution assume করে।

Skewed Distribution

Symmetric **নয়** — দুই পাশ সমান নয়।

ধরন	অন্য নাম	বৈশিষ্ট্য	উদাহরণ
Positively Skewed	Right-skewed	লেজ ডান দিকে লম্বা	Income, house price
Negatively Skewed	Left-skewed	লেজ বাম দিকে লম্বা	সহজ পরীক্ষার score

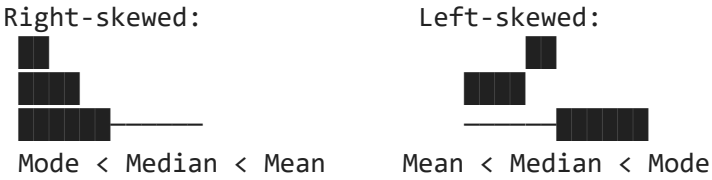

> ⚠️ Skewed data-তে Mean use করলে misleading result আসে — **Median ব্যবহার করো।**

সমাধান — Transformation:

Transformation	কখন
Log Transformation	সবচেয়ে সহজ ও common

Transformation	কখন
Box-Cox	শুধু positive data-তে
Yeo-Johnson	Positive ও negative উভয়তে

Long Tail Distribution

Distribution-এর কিছু extreme value center থেকে **অনেক দূরে লম্বা লেজের মতো** ছড়িয়ে থাকে।

Real-world উদাহরণ:

- YouTube views — কিছু video viral, বাকিগুলো কম
- Social media followers — কিছু account-এ লক্ষ লক্ষ, বাকিদের কম

> ⚠️ Long-tailed data সরাসরি model-এ দিলে model frequent cases-এ overfit করে এবং rare কিন্তু গুরুত্বপূর্ণ ঘটনা ignore করে।

সমাধান: Log transformation, Resampling, Outlier-aware models

Skewness vs Long Tail — পার্থক্য

Concept	Focus	উদাহরণ
Skewness	Data কোন দিকে হেলে আছে	Income distribution
Long Tail	Rare/extreme value কতটা বিস্তৃত	YouTube video views

---

Outlier Detection using IQR Fences

```
Q1 = np.percentile(data, 25)
Q3 = np.percentile(data, 75)
IQR = Q3 - Q1
lower_fence = Q1 - 1.5 * IQR
upper_fence = Q3 + 1.5 * IQR
outliers = data[(data < lower_fence) | (data > upper_fence)]
```

> 💡 **সব outlier খারাপ নয়!** Fraud detection বা rare disease prediction-এ outlier-ই সবচেয়ে গুরুত্বপূর্ণ case। সেক্ষেত্রে remove না করে আলাদাভাবে handle করো।

Part 5 — কখন Mean & SD বনাম Median & IQR?

পরিস্থিতি	ব্যবহার করো
Data roughly normal (bell-shaped)	Mean & SD

পরিস্থিতি	ব্যবহার করো
Skewed / outlier-heavy / messy data	Median & IQR
sklearn-এ robust scaling দরকার	`RobustScaler` → Median & IQR দিয়ে scale করে

```
data = [25, 27, 28, 29, 30, 31, 35, 500]
np.mean(data)     # → 88.1  (outlier-এ টেনে গেছে)
np.median(data)   # → 29.5  (স্থির থেকেছে)
```

> 💡 **Rule of thumb:** সবার আগে একটি `histogram` বা `boxplot` দেখো — তারপর সিদ্ধান্ত নাও।

Module Summary — এক নজরে

দিক	কী শিখলাম	Tools
Center	Mean, Median, Mode	`np.mean`, `np.median`, `pd.mode`
Spread	Variance, SD, IQR	`np.var`, `np.std`, `np.percentile`
Shape	Symmetric, Skewed, Long-tail	Histogram, Boxplot
Outlier	IQR method, Z-score, Modified Z-score	Manual + sklearn

---

Extra Practice Problem — সমাধান

Dataset: `[45, 48, 50, 52, 55, 58, 60, 62, 65, 68, 70, 72, 75, 78, 80, 85, 90, 95, 150, 500]`

প্রশ্ন	উত্তর
Range	500 - 45 = **455**
Sample Variance	**9718.41**
Sample SD	**98.58**
Q2 (Median)	**69.0**
Q1	**56.5**
Q3	**82.5**
IQR	82.5 - 56.5 = **26**
Lower Fence	56.5 - 1.5×26 = **17.5**
Upper Fence	82.5 + 1.5×26 = **121.5**
Outliers	**150 এবং 500** (২টি)

> 🎯 **পরের Module-এ:** Data describe করা থেকে সরে গিয়ে **Probability ও Bayes' Theorem** শিখবো — যা ML কীভাবে "শেখে" তার ভিত্তি তৈরি করবে।